

Aprendizado de Máquina B

Lourenço R. G. Araújo - DEST
Pedro O.S. Vaz de Melo - DCC

UFMG

Março de 2026

Apresentação da Disciplina

- **Ementa:** Aprendizado de Máquina com ênfase em técnicas de aprendizado profundo. Computação Diferenciável, Redes Neurais Modernas, Teorema da Aproximação Universal, Aprendizado de Representações, Viés e Variância em Redes Neurais, Redes Neurais para Dados Sequenciais, Redes Neurais Convolucionais, Modelos Generativos
- **Avaliação:** 3 provas (20 pontos cada), 1 TP (20 pontos) e Exercícios Práticos (20 pontos)


Apresentação da Disciplina

Livros de referência:

- Dive Into Deep Learning: <https://d2l.ai/>
- Deep Learning: <https://www.deeplearningbook.org/>

Redes Neurais Artificiais

Uma rede neural artificial é um modelo computacional, inspirado no cérebro humano, formado por nós (neurônios), que é capaz de aprender.



Redes Neurais Artificiais

Ideias usadas ainda hoje em aprendizado profundo começaram a ser desenvolvidas na década de 1940, com avanços nas décadas de 50 e 80, intercalados com períodos de estagnação até que a partir de 2012, temos um novo boom.

- 2012: Alexnet vence o ImageNet por larga margem popularizando a computação paralela em GPUs para treinamento de modelos
- 2014-2015: GANs se popularizam
- 2017: é proposta a arquitetura de Transformers

Redes Neurais Artificiais

Paradigmas de aprendizado:

- Aprendizado supervisionado
- Aprendizado não-supervisionado
- Aprendizado por reforço
- Aprendizado semi-supervisionado
- Aprendizado auto-supervisionado

Em geral, o processo de aprendizado é formulado como um problema de otimização (minimização ou maximização)

Redes Neurais Artificiais

Para o caso do aprendizado supervisionado, destacam-se 2 tarefas principais:

- Classificação
- Regressão

Vetor de entradas: $\mathbf{X}_{n \times m}$

Saída: $\mathbf{y}_{n \times 1}$ ou $\mathbf{y}_{n \times k}$

Matriz (ou tensor) de pesos: $\mathbf{W}$

Saída da rede neural: $f(\mathbf{W}, \mathbf{x}_i) = \hat{y}_i$

Função de perda: $\mathcal{L}(y_i, \hat{y}_i)$

Redes Neurais Artificiais

O processo de treinamento de uma rede neural corresponde a resolver o seguinte problema de otimização, com base no princípio de Minimização do Risco Empírico:

$$\min_{\mathbf{w}} \sum \mathcal{L}(y_i, \hat{y}_i)$$

o que corresponde a encontrar:

$$\mathbf{w}^* = \operatorname{argmin}_{\mathbf{w}} \sum \mathcal{L}(y_i, \hat{y}_i)$$

Redes Neurais Artificiais

Seja uma função $f(x) = y$ em que $x, y \in \mathbb{R}$.

A derivada de y em relação a x ($f'(x)$ ou $\frac{dy}{dx}$) fornece a inclinação de $f(x)$ de modo que: $f(x + \epsilon) \approx f(x) + \epsilon f'(x)$

Para valores suficientemente pequenos de ϵ :

$$f(x - \epsilon \cdot \text{sign}[f'(x)]) < f(x)$$

Técnica de minimização conhecida como Gradiente Descendente.

Redes Neurais Artificiais

Ou seja, caminhando na direção oposta da derivada da função $f(x)$, reduzimos o valor de $f(x)$ até um mínimo.

Quando $f'(x) = 0$, podemos ter um mínimo, um máximo ou um ponto de sela.


Mínimos e máximos podem ser locais ou globais.

Redes Neurais Artificiais

A regra da cadeia para diferenciação nos ensina como obter a derivada de funções compostas por outras funções:

Seja $y = f(g(x))$, então:

$$\frac{dy}{dx} = \frac{df}{dg} = \frac{df}{dg} \frac{dg}{dx}$$



Redes Neurais Artificiais - Diferenciação Automática

Aplicar a regra da cadeia é simples e direto, mas conforme as funções crescem (por exemplo, uma rede neural com milhares de neurônios) torna-se impossível na prática.

AutoGrad

Redes Neurais Artificiais - Diferenciação Automática

Algumas formas de calcular derivadas computacionalmente:

- Diferenciação numérica: erros de arredondamento
- Diferenciação simbólica: código ineficiente
- **Diferenciação automática**

Além disso, a diferenciação automática é eficiente para calcular derivadas de maior ordem e para calcular derivadas parciais em relação a muitas variáveis.

Redes Neurais Artificiais - Diferenciação Automática

Qualquer cálculo que um computador executa é uma combinação de operações aritméticas e funções elementares pras quais conhecemos as derivadas.

Aplicando a regra da cadeia sucessivamente, somos capazes de obter derivadas a baixo custo.

Redes Neurais Artificiais - Diferenciação Automática

$$y = f(g(h(x)))$$

$$w_1 = h(x)$$

$$w_2 = g(w_1)$$

$$y = f(w_2)$$

Pela regra da cadeia, sabemos que:

$$\frac{\partial y}{\partial x} = \frac{\partial y}{\partial w_2} \frac{\partial w_2}{\partial w_1} \frac{\partial w_1}{\partial x} = \frac{\partial f(w_2)}{\partial w_2} \frac{\partial g(w_1)}{\partial w_1} \frac{\partial h(x)}{\partial x}$$

Redes Neurais Artificiais - Diferenciação Automática

Bibliotecas de diferenciação automática, tais como `torch.autograd`, contém correspondências entre funções e suas derivadas.

```
- name: cos(Tensor self) -> Tensor  
  self: grad * -self.sin().conj()  
  result: auto_element_wise
```

Além disso, é possível definir novas funções para serem aplicadas e que usam `autograd` para cálculo de derivadas.

- https://docs.pytorch.org/tutorials/beginner/examples_autograd/polynomial_custom_function.html