

Aprendizado de Máquina B

Lourenço R. G. Araújo - DEST
Pedro O.S. Vaz de Melo - DCC

UFMG

Março de 2026

Neurônios Artificiais

Na nossa primeira aula, definimos uma rede neural como sendo:

- Uma rede neural artificial é um modelo computacional, inspirado no cérebro humano, formado por nós (**neurônios**), que é capaz de aprender.

Os modelos de neurônio que usamos em redes neurais possuem 3 elementos básicos:

- 1 Um conjunto de pesos (sinápticos): os pesos ligam as entradas aos neurônios (e os neurônios entre si)
- 2 Um somador que realiza uma soma ponderada das entradas pelos pesos
- 3 Uma função de ativação que pode introduzir não linearidade e limites à amplitude da resposta

Neurônios Artificiais




Imagem retirada do livro Neural Networks and Learning Machines - Haykin

Neurônios Artificiais

Retomando a ideia de uma rede neural como uma função do tipo $f(\mathbf{x}, \mathbf{w}, b)$, podemos escrever a saída da rede neural como sendo:

$$\hat{y} = f(\mathbf{x}, \mathbf{w}, b) = \varphi\left(\sum_{j=1}^m w_j x_j + b\right)$$

Perceptron

- O perceptron é o primeiro (e mais simples) modelo de rede neural capaz de aprender de forma supervisionada
- O perceptron é capaz de classificar dados de duas classes, **desde que sejam linearmente separáveis**
- Um neurônio, com pesos e viés ajustáveis
- Algoritmo de treinamento que ajusta pesos e viés a partir dos dados e converge, posicionando o hiperplano de separação entre as classes

Perceptron

- O neurônio utilizado no algoritmo do Perceptron possui função de ativação não linear, do tipo limiar (função sinal).
- Uma combinação linear das entradas, ponderadas pelos pesos, somada ao viés é submetida à função sinal. Se a saída da função de ativação é positiva, atribui-se o resultado $+1$, se é negativa, atribui-se -1 .

Perceptron

TABLE 1.1 Summary of the Perceptron Convergence Algorithm

Variables and Parameters:

$\mathbf{x}(n)$ = $(m + 1)$ -by-1 input vector

$$= [+1, x_1(n), x_2(n), \dots, x_m(n)]^T$$

$\mathbf{w}(n)$ = $(m + 1)$ -by-1 weight vector

$$= [b, w_1(n), w_2(n), \dots, w_m(n)]^T$$

b = bias

$y(n)$ = actual response (quantized)

$d(n)$ = desired response

η = learning-rate parameter, a positive constant less than unity

1. *Initialization.* Set $\mathbf{w}(0) = \mathbf{0}$. Then perform the following computations for time-step $n = 1, 2, \dots$
2. *Activation.* At time-step n , activate the perceptron by applying continuous-valued input vector $\mathbf{x}(n)$ and desired response $d(n)$.
3. *Computation of Actual Response.* Compute the actual response of the perceptron as

$$y(n) = \text{sgn}[\mathbf{w}^T(n)\mathbf{x}(n)]$$

where $\text{sgn}(\cdot)$ is the signum function.

4. *Adaptation of Weight Vector.* Update the weight vector of the perceptron to obtain

$$\mathbf{w}(n + 1) = \mathbf{w}(n) + \eta[d(n) - y(n)]\mathbf{x}(n)$$

where

$$d(n) = \begin{cases} +1 & \text{if } \mathbf{x}(n) \text{ belongs to class } \mathcal{C}_1 \\ -1 & \text{if } \mathbf{x}(n) \text{ belongs to class } \mathcal{C}_2 \end{cases}$$

5. *Continuation.* Increment time step n by one and go back to step 2.

Perceptron

- O perceptron separa duas regiões por um hiperplano do tipo

$$\sum_{j=1}^m w_j x_j + b = 0$$

- É garantido que o perceptron converge em $n < n_{max}$ iterações, desde que as classes sejam linearmente separáveis

Perceptron

Teorema de Convergência do Perceptron

Sejam 2 subconjuntos dos vetores de treinamento $\mathcal{X}_1$ e $\mathcal{X}_{-1}$ linearmente separáveis. O algoritmo do perceptron converge após n_o iterações, de forma que:

$$w(n_o) = w(n_o + 1) = w(n_o + 2) = \dots$$

é um vetor de solução e $n_o \leq n_{max}$

A prova deste teorema é de fácil acompanhamento e pode ser encontrada no capítulo 1 do livro: “Neural Networks and Learning Machines” de Simon Haykin

Perceptron

- O teorema de Convergência do Perceptron nos garante que, desde que os dados sejam linearmente separáveis, encontraremos um hiperplano capaz de separar os dados.
- Não há, no entanto, garantia de otimalidade para o hiperplano encontrado.

Perceptron versus Classificador de Bayes

- Quando os dados de ambas as classes vêm de uma distribuição Gaussiana com mesma matriz de covariância, o classificador ótimo (Classificador de Bayes, que minimiza o risco médio) é um hiperplano:

$$\mathbf{w} = \Sigma^{-1}(\mu_1 - \mu_2)$$

$$b = 0.5(\mu_2^T \Sigma^{-1} \mu_2 - \mu_1^T \Sigma^{-1} \mu_1)$$

- O hiperplano não é o mesmo obtido pelo perceptron

Perceptron versus Classificador de Bayes

- Para convergência do Perceptron é necessário que os dados sejam linearmente separáveis, o que não é necessário para o classificador de bayes (até porque, 2 distribuições gaussianas são, necessariamente, não separáveis de forma linear)
- Enquanto o classificador de Bayes é paramétrico e fortemente dependente da distribuição dos dados, o Perceptron é não paramétrico com relação às distribuições de probabilidade

Perceptron em *Batches*

- O algoritmo do perceptron que foi apresentado corrige os pesos de acordo com cada exemplo que é apresentado
- Não há referência explícita a uma função de custo
- O uso da função sinal inviabiliza o uso de gradientes

Perceptron em *Batches*

$$\mathcal{L}(\mathbf{w}) = \sum_{\mathbf{x}(n) \in \mathcal{X}} (-\mathbf{w}^T \mathbf{x}(n) d(n))$$

- $\mathcal{X}$ corresponde ao subconjunto de amostras classificadas erroneamente
- Função diferenciável com respeito aos pesos $\mathbf{w}$

$$\nabla \mathcal{L}(\mathbf{w}) = \sum_{\mathbf{x}(n) \in \mathcal{X}} -\mathbf{x}(n) d(n)$$

Perceptron em *Batches*

Usando o método de gradiente descendente:

$$\mathbf{w}(n+1) = \mathbf{w}(n) - \eta \nabla \mathcal{L}(\mathbf{w}(n))$$

$$\mathbf{w}(n+1) = \mathbf{w}(n) + \eta \sum_{\mathbf{x}(n) \in \mathcal{X}} \mathbf{x}(n) d(n)$$

Limitações do Perceptron

- A classificação usando o perceptron só é bem sucedida se os dados são linearmente separáveis, mesmo se outra função de ativação é utilizada
- Clássico exemplo do XOR
- Minsky e seus coautores foram extremamente críticos ao Perceptron, chegando a afirmar que, mesmo em múltiplas camadas, eles não seriam capazes de superar as limitações do modelo original.