

Aprendizado de Máquina B

Funções de Ativação

Lourenço R. G. Araújo - DEST
Pedro O.S. Vaz de Melo - DCC


UFMG

Março de 2026

Funções de Ativação

- $f(\mathbf{x}, \mathbf{w}) = \varphi(\mathbf{w}^T \mathbf{x})$
- A função de ativação $\varphi(\cdot)$ é responsável por introduzir não-linearidades em uma rede neural
- A função de ativação do perceptron é a função sinal, herdada do neurônio de McCulloch-Pitts
- Em redes neurais modernas, são usados diferentes tipos de neurônio

Funções de Ativação



- Neurônios nas camadas ocultas têm funções de ativação diferentes dos neurônios nas camadas de saída
- Vamos considerar problemas de classificação e problemas de regressão
 - 2 classes
 - Mais do que 2 classes

Distribuição de Bernoulli

Considere um experimento aleatório com dois desfechos possíveis:
A ou B, 0 ou 1, Sucesso ou Fracasso¹

$$P(X = 1) = p \text{ e } P(X = 0) = 1 - p$$

$$P(X = x) = p^x(1 - p)^{1-x}, x = 0, 1$$

$$E(X) = p, \text{Var}(X) = p(1 - p)$$

$$X \sim \text{Bern}(p)$$

¹fracasso (ou sucesso) não possuem, necessariamente, a conotação negativa (ou positiva) tipicamente associada com os termos

Distribuição *Multinoulli*

Consideramos um experimento aleatório com k desfechos possíveis, em que temos um vetor de probabilidades associadas a cada um dos $k - 1$ desfechos, com a probabilidade do desfecho k sendo dada por $1 - \mathbf{1}^T \mathbf{p}$

A distribuição Multinoulli é um caso particular da distribuição multinomial (da mesma forma que a distribuição de Bernoulli é um caso particular da distribuição binomial)

Distribuição Normal

A distribuição normal é uma distribuição simétrica, em formato de sino e também é conhecida como modelo Gaussiano.

Uma variável aleatória é normalmente distribuída com parâmetros μ e σ^2 , com a notação usual $X \sim N(\mu, \sigma^2)$, se a sua função de densidade de probabilidade for dada por:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right], \quad -\infty \leq x \leq \infty, -\infty \leq \mu \leq \infty, \sigma^2 > 0$$

Estimador de Máxima Verossimilhança - MLE

- Considerando um conjunto de amostras $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$, gerados de forma independente a partir de uma distribuição de probabilidade desconhecida.
- Se consideramos uma forma paramétrica para a distribuição de probabilidade, do tipo $p_{model}(\mathbf{x}, \theta)$ que mapeia $\mathbf{x}$ para uma probabilidade, então definimos o estimador de máxima verossimilhança como:

$$\theta_{ML} = \underset{\theta}{\operatorname{argmax}} p_{model}(\mathbf{X}, \theta)$$

Estimador de Máxima Verossimilhança - MLE

- Considerando um conjunto de amostras $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$, gerados de forma independente a partir de uma distribuição de probabilidade desconhecida.
- Se consideramos uma forma paramétrica para a distribuição de probabilidade, do tipo $p_{model}(\mathbf{x}, \theta)$ que mapeia $\mathbf{x}$ para uma probabilidade, então definimos o estimador de máxima verossimilhança como:

$$\theta_{ML} = \underset{\theta}{\operatorname{argmax}} p_{model}(\mathbf{X}, \theta)$$

$$\theta_{ML} = \underset{\theta}{\operatorname{argmax}} \prod_{i=1}^n p_{model}(\mathbf{x}_i, \theta)$$

Estimador de Máxima Verossimilhança - MLE

$$\theta_{ML} = \operatorname{argmax}_{\theta} \sum_{i=1}^n \log p_{model}(\mathbf{x}_i, \theta) = \operatorname{argmin}_{\theta} \sum_{i=1}^n -\log p_{model}(\mathbf{x}_i, \theta)$$

$$\theta_{ML} = \operatorname{argmax}_{\theta} \mathbb{E}_{X \sim \hat{p}_{data}} \log p_{model}(\mathbf{x}, \theta)$$

- Maximizar a verossimilhança pode ser entendido como “casar” o máximo possível o modelo à distribuição empírica dos dados.
- Minimizar o negativo do log da verossimilhança ou minimizar a divergência KL levam ao mesmo estimador que maximizar a verossimilhança

Log-verossimilhança condicional

- Para prever $\hat{y}$ a partir de $\mathbf{x}$, generalizamos a ideia do MLE para estimarmos a probabilidade condicional dada por $P(y|\mathbf{x}, \theta)$
- Se temos um conjunto de observações rotuladas $\mathbf{X}, \mathbf{y}$, o estimador de máxima verossimilhança é dado por:

$$\theta_{ML} = \underset{\theta}{\operatorname{argmax}} P(\mathbf{y}|\mathbf{X}, \theta) = \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^n \log P(y_i|\mathbf{x}_i, \theta)$$

Regressão - Saída Gaussiana

- Usamos um neurônio de saída linear quando queremos prever a média de uma distribuição Gaussiana
- Formulação típica de um problema de regressão com resposta contínua

$$p(y|\mathbf{x}) \sim \mathcal{N}(f(\mathbf{x}, \theta), \sigma^2)$$

Regressão - Saída Gaussiana

- Ao maximizarmos a verossimilhança no caso de um neurônio de saída linear, estamos minimizando o MSE

Classificação - Saída Bernoulli

- Para um problema de classificação com saída binária, modelamos o problema como seguindo uma distribuição de Bernoulli e buscamos maximizar a verossimilhança condicional

$$\max P(\mathbf{y}|\mathbf{X}, \theta)$$

- Nosso neurônio de saída precisa prever apenas o valor de $P(1|\mathbf{x})$, já que $P(0|\mathbf{x}) = 1 - P(1|\mathbf{x})$, desde que $P(1|\mathbf{x})$ esteja dentro do intervalo $[0, 1]$

Classificação - Saída Bernoulli

- Para um problema com saída seguindo a distribuição de Bernoulli definimos a saída do nosso neurônio como sendo:

$$\hat{y} = \sigma(\mathbf{w}^T h)$$

- $\sigma(\cdot)$ é a função sigmoide logística, definida como:

$$\sigma(x) = \frac{1}{1 + \exp(-x)}$$

Classificação - Saída Bernoulli

- Com um neurônio de saída com função logística, o estimador de máxima verossimilhança é obtido minimizando-se $-\log P(y|\mathbf{x})$
- Com alguma manipulação:

$$\theta_{ML} = \underset{\theta}{\operatorname{argmin}} \log(1 + \exp((1 - 2y)\mathbf{w}^T h))$$

- A função $\log(1 + \exp(x))$ é conhecida como softplus

Classificação - Saída *Multinoulli*

- Para variáveis categóricas de múltiplas saídas, usamos a saída Softmax, que é uma generalização da saída sigmoidal
- $$\text{softmax}(z)_i = \frac{\exp(z_i)}{\sum_j \exp(z_j)}$$
- A softmax leva a uma versão suavizada de uma estratégia *winner-takes-all*