

# Aprendizado de Máquina B

## Regularização

Lourenço R. G. Araújo - DEST  
Pedro O.S. Vaz de Melo - DCC

UFMG

Março de 2026

# Regularização

- Com o que vimos até aqui, somos capazes de construir redes neurais com bom desempenho nos conjuntos de treinamento: **minimização da função perda para os dados de treinamento**
- Maximizar a verossimilhança nos conjuntos de treinamento nem sempre se traduz em um bom desempenho de generalização
- Como construir modelos que generalizam bem?

# Viés e Variância

- Pensando em uma resposta do tipo  $y = f(x) + \epsilon$ , de forma que  $E[\epsilon] = 0$  e  $Var[\epsilon] = \sigma^2$
- Definimos o valor esperado do erro como sendo:

$$E[(y - \hat{y})^2]$$

- Vamos mostrar que o erro pode ser decomposto em viés e variância do modelo mais um termo de ruído dos dados

## Viés e Variância

$$E[(y - \hat{y})^2] = E[(y - f(x) + f(x) - \hat{y})^2]$$

Agrupando  $(y - f(x))$  e  $(f(x) - \hat{y})$ , chegamos a:

$$E[(y - \hat{y})^2] = E[(y - f(x))^2 + (f(x) - \hat{y})^2 + 2(y - f(x))(f(x) - \hat{y})]$$

Sabemos que  $E[X + Y] = E[X] + E[Y]$ , então:

$$E[(y - \hat{y})^2] = E[(y - f(x))^2] + E[(f(x) - \hat{y})^2] + 2E[(y - f(x))(f(x) - \hat{y})]$$

# Viés e Variância

Vamos lembrar que:

- $E[\epsilon] = 0$  e  $Var[\epsilon] = \sigma^2$
- $Var(X) = E[X^2] - E^2[X]$

$$y - f(x) = \epsilon$$

$$2E[(y - f(x))(f(x) - \hat{y})] = 2E[\epsilon(f(x) - \hat{y})] = 2E[\epsilon]E[(f(x) - \hat{y})] = 0$$

$$E[(y - f(x))^2] = E[\epsilon^2] = Var[\epsilon] + E^2[\epsilon] = Var[\epsilon] = \sigma^2$$

## Viés e Variância

$$E[(y - \hat{y})^2] = \sigma^2 + E[(f(x) - \hat{y})^2]$$

$$E[(f(x) - \hat{y})^2] = E[(f(x) - E[\hat{y}] + E[\hat{y}] - \hat{y})^2]$$

$$E[(f(x) - \hat{y})^2] = E[(f(x) - E[\hat{y}])^2 + (E[\hat{y}] - \hat{y})^2 + 2(f(x) - E[\hat{y}])(E[\hat{y}] - \hat{y})]$$

$$\begin{aligned} E[(f(x) - \hat{y})^2] &= E[(f(x) - E[\hat{y}])^2] + E[(E[\hat{y}] - \hat{y})^2] \\ &\quad + 2E[(f(x) - E[\hat{y}])(E[\hat{y}] - \hat{y})] \end{aligned}$$

$$E[(f(x) - \hat{y})^2] = E[(f(x) - E[\hat{y}])^2] + E[(E[\hat{y}] - \hat{y})^2]$$

# Viés e Variância

$$E[(f(x) - \hat{y})^2] = E[(f(x) - E[\hat{y}])^2] + E[(E[\hat{y}] - \hat{y})^2]$$

- O primeiro termo do lado direito corresponde ao Viés ao quadrado do modelo: valor esperado do erro quadrático entre o modelo e a função que desejamos aprender
- O segundo termo corresponde à variância do modelo (é a própria definição de  $Var[\hat{y}]$ )

# Viés e Variância




$$E[(y - \hat{y})^2] = \sigma^2 + E[(f(x) - E[\hat{y}])^2] + Var[\hat{y}]$$

$$E[(y - \hat{y})^2] = \sigma^2 + \text{Viés}(\hat{y})^2 + Var[\hat{y}]$$

- $\sigma^2$  não depende do modelo utilizado e, portanto, não pode ser minimizado, é o chamado erro irreduzível
- Quando treinamos um modelo, atuamos sobre os valores de viés e variância
- Em geral, modelos de maior flexibilidade terão menor viés e maior variância, e vice-versa
- Raciocínio semelhante pode ser construído para funções de perda de classificação (Entropia Cruzada)



# Viés e Variância



- **ATENÇÃO:** em redes neurais profundas às vezes observamos um comportamento conhecido como *Double Descent*

# Underfitting e Overfitting

$$y = f(x) + \epsilon$$

- O overfitting ocorre quando o modelo se ajusta excessivamente aos dados de treinamento, modelando ruído (interpolamos o conjunto de treinamento)
- Já o underfitting acontece quando o modelo é simples demais para modelar a função  $f(x)$

Pensando em viés e variância, um modelo subajustado é um modelo de alto viés, já um modelo sobreajustado é um modelo de alta variância

# Underfitting e Overfitting

- Idealmente, gostaríamos que nossos modelos atingissem baixo viés e baixa variância
- Pensando em redes neurais, sabemos que são modelos extremamente flexíveis, capazes portanto de baixo viés
- Algumas estratégias são adotadas para limitar a variância, e impedir que exploda

# Underfitting e Overfitting

- Redes neurais quando estão subajustadas podem ser melhoradas com algumas estratégias:
  - 1 Mais neurônios/mais camadas
  - 2 Mais épocas de treinamento
  - 3 Diferentes arquiteturas
  - 4 Diferentes algoritmos de otimização (mínimos “melhores”)
- Redes neurais quando sobreajustadas podem ser melhoradas com algumas estratégias:
  - 1 Regularização
  - 2 Mais dados
  - 3 Diferentes arquiteturas

# Regularização

- Penalização L2
- Penalização L1
- *Early Stopping*
- *Data Augmentation*
- *Dropout*

Os três últimos itens serão vistos mais adiante, quando estivermos falando de redes convolucionais

# Regularização

- Para a capacidade de generalização de uma rede neural, mais do que a quantidade de neurônios, importa o tamanho da norma dos seus pesos.
- Intuitivamente, podemos entender que grandes valores de pesos (em módulo) implicam em grandes variações em  $\hat{y}$  para pequenas variações de entrada
- Grandes valores em módulo de pesos, geralmente, estão associados a complexidade excessiva de explicação

# Regularização

Com a penalização com norma L1 e com norma L2, controlamos o valor da norma dos vetores de pesos:

- Norma L2:  $\|\theta\|_2^2 = \sum_i \theta_i^2$
- Norma L1:  $\|\theta\|_1 = \sum_i |\theta_i|$

A função objetivo do problema de otimização passa a ser dada por:

$$J = \mathcal{L}(y, \hat{y}) + \lambda \|\theta\|_2^2 \text{ ou } \mathcal{L}(y, \hat{y}) + \lambda \|\theta\|_1$$

IMPORTANTE: Penalização de norma L1 e L2 não é normalmente aplicada aos vieses dos neurônios

# Regularização

O impacto do uso de penalização nas equações de backpropagation é pequeno:

$$\text{Norma L2: } \theta_j^{t+1} = \theta_j^t - \text{LearningRate} \left[ \frac{\partial \mathcal{L}}{\partial \theta_j} \Big|_{\theta_j^t} + 2\lambda \theta_j^t \right]$$

$$\text{Norma L1: } \theta_j^{t+1} = \theta_j^t - \text{LearningRate} \left[ \frac{\partial \mathcal{L}}{\partial \theta_j} \Big|_{\theta_j^t} + \lambda (I(\theta_j^t > 0) - I(\theta_j^t < 0)) \right]$$

O valor de  $\lambda$  é normalmente escolhido em conjunto de validação (menor valor de função de custo no conjunto de validação)

- $\lambda = 0$ : modelo sem penalização
- $\lambda$  muito grande: modelo extremamente penalizado  $\rightarrow$  underfit



# Regularização

- A regularização com norma L2 (também conhecida como weight decay ou ridge), tem como objetivo impedir o surgimento de pesos com valores extremos (muito positivos ou muito negativos)
- A regularização com norma L1 (também conhecida como LASSO) resulta em conjuntos de pesos mais esparsos, com vários coeficientes iguais a zero.

# Regularização


Uma forma de olhar para as novas funções objetivo é pensar em um problema de otimização restrita:

$$\min_{\theta} \mathcal{L}(y, \hat{y})$$

sujeito a:

$$\|\theta\|_q < \gamma$$

# Regularização



**FIGURE 3.11.** Estimation picture for the lasso (left) and ridge regression (right). Shown are contours of the error and constraint functions. The solid blue areas are the constraint regions  $|\beta_1| + |\beta_2| \leq t$  and  $\beta_1^2 + \beta_2^2 \leq t^2$ , respectively, while the red ellipses are the contours of the least squares error function.