


Lista de Revisão

Redes Neurais

1. Considere uma rede com uma camada escondida mostrada abaixo:



Assumindo que cada neurônio de uma camada $[l]$ aplica uma função $f(Z^{[l]}) = A^{[l]}$, onde Z é calculado como $W^{[l]}A^{[l-1]} + b^{[l]}$ e que a entrada pode ser escrita como a camada zero: $A^{[0]} = x$.

- (a) Quais são as dimensões de $W^{[1]}$, $b^{[1]}$, $W^{[2]}$ e $b^{[2]}$?
 - (b) Quais são as dimensões de $Z^{[1]}$ e $A^{[1]}$?
2. Além da sigmóide, a tangente hiperbólica e ReLU são funções de ativação comumente utilizadas em redes neurais.
 - (a) Encontre a derivada da tangente hiperbólica $\tanh x = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ com respeito a x . Em qual valor de x a derivada atinge seu valor máximo?
 - (b) Encontre a derivada da função $\text{ReLU}(x) = \max(0, x)$ para $x < 0$ e $x > 0$.
 - (c) Sejam a, b constantes positivas. Expresse a derivada da função $f(x) = a \cdot \tanh(bx)$ (sigmóide anti-simétrica) em termos da própria função.

Regularização

1. Considere a seguinte função objetiva de mínimos quadrados regularizada L2 para uma regressão linear:

$$f(w) = \|w^T x - y\|^2 + \lambda \|w\|^2.$$

Como a escolha de λ afeta a reta estimada?

2. Considere uma rede neural com duas features de entrada e uma camada escondida de dois nós. Sejam $W^{[1]}, b^{[1]}, W^{[2]}, b^{[2]}$ os pesos da rede:

$$W^{[1]} = \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix}, \quad b^{[1]} = \begin{bmatrix} -2 \\ 4 \end{bmatrix},$$

$$W^{[2]} = \begin{bmatrix} 1 \\ 5 \end{bmatrix}, \quad b^{[2]} = [-4].$$

E os gradientes em relação à função de perda:


$$\frac{\partial J}{\partial W^{[1]}} = \begin{bmatrix} -10 & 5 \\ 1 & 2.5 \end{bmatrix}, \quad \frac{\partial J}{\partial b^{[1]}} = \begin{bmatrix} 3 \\ -3 \end{bmatrix},$$

$$\frac{\partial J}{\partial W^{[2]}} = \begin{bmatrix} -1 \\ 2 \end{bmatrix}, \quad \frac{\partial J}{\partial b^{[2]}} = [-2].$$

- a) Seja $\alpha = 0.1$, faça uma iteração do backpropagation nos pesos da rede. Além disso, considerando a regularização L2 com $\lambda = 0.5$, atualize os pesos considerando a regularização.
- b) Qual diferença você nota entre os pesos com e sem regularização?
- c) Ao final de várias iterações, após a rede convergir, o que você espera que seja a diferença entre os pesos das duas redes? Explique qual será o efeito provável da regularização no erro no conjunto de testes e por que isso ocorre.

Gradiente Descendente

1. Suponha que o custo J do seu algoritmo de aprendizado, plotado como uma função do número de iterações, seja representado no gráfico abaixo. A partir da análise do gráfico, explique qual deve ter sido o algoritmo utilizado: gradiente descendente em batch ou gradiente descendente estocástico



2. Começando do ponto $(-0.1, 2)$, mostre como se comporta o algoritmo gradiente descendente para encontrar o mínimo da função $f(x, y) = 10x^2 + (y/6)^2$ (calcule 2 iterações do algoritmo de gradiente descendente usando taxa de aprendizado de 0.1). Em seguida, mostre o efeito de se utilizar um termo de momento. Discuta os resultados

Backpropagation

1. Uma rede MLP com uma camada oculta de 2 neurônios relu e uma saída linear, é inicializada com pesos na camada oculta $\mathbf{w}_1^{(1)} = \{0.1, 0.12\}$ $\mathbf{w}_2^{(1)} = \{0.23, -0.1\}$ e vieses na camada oculta $b^{(1)} = \{0, 0\}$ e pesos e vieses iguais a 0.1 na camada de saída. Para uma entrada $\mathbf{x} = \{1, -1\}$ e $y = 0.5$, e função de perda MSE, execute o backpropagation para atualizar os pesos.